



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Análise Exploratória - PMBG

André Soares, aluno n.º 98306
António Navalhas, aluno n.º 108187
Lifan Chen, aluno n.º 136520
Pedro Lourenço, aluno n.º 133931

Mestrado: Ciência de Dados

Unidade curricular: Processamento e Modelação de Big Data

Professor Auxiliar Alexandre Passos de Almeida,
ISCTE – Instituto Universitário de Lisboa

Abril 2026

Índice

1. <i>Introdução breve ao conjunto de dados</i>	3
2. <i>Descrição da estrutura e das variáveis do dataset</i>	3
3. <i>Principais resultados da análise exploratória</i>	4
4. <i>Problemas identificados nos dados e possíveis etapas de limpeza.</i>	4
5. <i>Questões de investigação propostas</i>	5
6. <i>Métodos analíticos sugeridos e respetiva justificação</i>	5
<i>Anexos</i>	6

1. Introdução breve ao conjunto de dados

O presente projeto utiliza o *dataset* “*Billboard Hot 100 (2021-09-14)*”, no qual estão expressas informações sobre as músicas que integram o *ranking Billboard Hot 100* nos Estados Unidos, com periodicidade semanal. Este *ranking* é um dos principais indicadores de sucesso na indústria musical, sendo o mesmo construído com base em vendas, reprodução em rádio e *streaming online*.

O conjunto de dados é composto por dois ficheiros principais: *billboard.csv*, que contém a evolução semanal das músicas no *ranking*, e *audio_features.csv*, que inclui características musicais extraídas do *Spotify*, como género, energia, dança, tempo e popularidade. Uma característica relevante deste *dataset* é a sua natureza longitudinal, uma vez que cada música pode surgir em várias semanas consecutivas, e cada observação corresponde a uma combinação entre música e semana. Esta estrutura permite analisar a evolução do desempenho das músicas ao longo do tempo, identificando diferentes padrões de comportamento no *ranking*. Deste modo, o *dataset* revela-se adequado para a aplicação de métodos de aprendizagem não supervisionada, permitindo explorar e identificar diferentes perfis de sucesso musical com base nas trajetórias das músicas e nas suas características sonoras.

2. Descrição da estrutura e das variáveis do dataset

O *dataset* em análise é composto por dois ficheiros complementares, *billboard.csv* e *audio_features.csv*, que em conjunto permitem estudar o desempenho temporal das músicas no *ranking* e, as suas características musicais. Quanto ao ficheiro *billboard.csv*, este constitui a base principal do *dataset* e apresenta uma estrutura longitudinal e, entre as variáveis mais relevantes destacam-se *week_id*, que identifica a semana da observação, *week_position*, que indica a posição ocupada no *ranking* (entre 1 e 100), *song* e *performer*, que identificam a música e o artista, e *song_id*, que funciona como identificador único da combinação música-artista. Adicionalmente, incluem-se variáveis que descrevem a evolução da música ao longo do tempo, como *previous_week_position*, que indica a posição na semana anterior, *peak_position*, que representa a melhor posição alcançada até à data e *weeks_on_chart*, que indica o número de semanas que a música permaneceu no *ranking*. Por sua vez, o ficheiro *audio_features.csv* contém informação adicional sobre as músicas, incluindo variáveis categóricas, como *spotify_genre* e *spotify_track_album*, bem como variáveis numéricas como *danceability*, *energy*, *loudness*, *speechiness*, *acousticness*, *instrumentalness*, *liveness*, *valence*, tempo e *spotify_track_popularity*.

Analisando a estrutura dos dados, conclui-se que o ficheiro *billboard.csv* tem carácter temporal, apresentando múltiplas observações por música, enquanto que o ficheiro *audio_features.csv* apresenta uma

estrutura mais singular, representando uma observação por música. A ligação entre os ficheiros é feita através da variável *song_id*, servindo esta como chave estrangeira entre os ficheiros.

3. Principais resultados da análise exploratória

De seguida, realizou-se uma análise exploratória aos dados, tendo-se identificado as seguintes conclusões:

- Relativamente ao ficheiro *audio_features.csv*, este é composto por 29.503 observações e 22 variáveis, das quais 7 são do tipo texto, 1 categórica, e 14 variáveis numéricas. No ficheiro, não foi detetada a presença de valores omissos (nulls) na leitura inicial, embora se observe uma elevada presença de valores ‘NA’, que correspondem a valores em falta, conforme Anexo 1, bem como a presença de duplicados, recomendando-se por isso a necessidade de uma etapa de limpeza e pré-processamento aos dados. Recomenda-se também uma análise aos *outliers*, após a fase de limpeza, dado que antes da mesma não é possível fazer a análise devido à incorreta atribuição dos tipos de dados às variáveis numéricas.

- Quanto ao ficheiro *billboard.csv*, este é constituído por 327.895 observações e 10 variáveis, das quais 4 são do tipo de texto, 5 numéricas e, 1 variável do tipo *date*. Dado que o ficheiro corresponde a uma tabela de factos, procedeu apenas a verificação da existência de valores omissos e, à verificação de registos duplicados, concluindo-se que o ficheiro não apresenta registos duplicados, contudo detetou-se a presença de valores “NA” na variável “*previous_week_position*”.

4. Problemas identificados nos dados e possíveis etapas de limpeza.

Dadas as inconsistências nos dados supramencionadas, nomeadamente quanto ao tipos de dados, identificando-se variáveis com o tipo de dado errado, como por exemplo, a variável *energy* que se encontra classificada como *string*, quando deveria ser classificada como numérica do tipo *double*; valores ausentes, dada a elevada presença de NA’s; e registos duplicados; recomendam-se as seguintes etapas de limpeza:

- **Correção dos tipos de dados**, efetuando-se a conversão das variáveis para os formatos corretos, de forma a permitir uma etapa de análise estatística;

- **Remoção de duplicados**, eliminando-se as linhas repetidas para garantir a integridade da análise;

- **Tratamento dos valores NA**, substituindo os mesmos por métricas centrais (média ou mediana), ou eliminando os mesmos, consoante ao contexto do problema;

- **Análise e tratamento de *outliers***, pois após a correção dos tipos de dados, torna-se possível proceder à identificação de *outliers* e aplicar o devido tratamento, como a substituição de valores utilizando o método do Intervalo Interquartil (IQR), ou eliminação dos dados consoante ao contexto do problema;

Relativamente ao ficheiro billboard.csv, e este trata-se de uma tabela de factos que não apresenta registos duplicados, embora contenha valores 'NA' em algumas variáveis, pelo que apenas será necessário efetuar a correção do tipo de dados.

5. Questões de investigação propostas

Para o conjunto de dados mencionado, propõem-se as seguintes questões de investigação:

- Das catorze variáveis numéricas no ficheiro audio_features é possível reduzir a dimensionalidade da amostra, agrupando variáveis correlacionadas?
- Com base na redução feita, é possível agrupar as variáveis em grupos homogéneos pelo seu som?
- Como se comportam as músicas ao longo do tempo? Existem algum padrão entre hits e slow burns?
- Existem músicas verdadeiramente únicas no top 100?

6. Métodos analíticos sugeridos e respetiva justificação

O objetivo da análise, assenta num modelo de abordagem não supervisionada, dado que o objetivo não é prever um rótulo conhecido, mas sim descobrir estruturas e padrões ocultos nos dados. Assim, de forma a responder às questões propostas, sugerem-se as seguintes estratégias e métodos:

- **Análise de Componentes Principais (PCA)**, pois dada a existência de catorze variáveis numéricas referentes às características do som, é provável a presença de métricas que transmitam informação redundante, pelo que a aplicação de métodos de redução de dimensionalidade justifica-se pela necessidade de sintetizar e agrupar variáveis correlacionadas em componentes principais;

- **Algoritmo K-Means (Clustering)**, de modo a agrupar as músicas em conjuntos homogéneos pelo seu som, aplicando-se o algoritmo K-Means sobre as componentes extraídas através da PCA. Numa fase de análise de resultados, introduzir-se-á a variável **spotify_genre** como variável de perfilagem, para aferir se o padrão de agrupamento detetado pelo algoritmo encontra correspondência com os géneros musicais reais;

- **Isolation Forest**, de forma a identificar músicas com características atípicas ou extremas no Top 100, pois segundo este algoritmo, as músicas com um padrão comum necessitarão de múltiplos cortes lógicos para

serem separadas das restantes, enquanto que os *outliers* registarão um número de cortes bastante inferior, permitindo o seu rápido isolamento e, possibilitando uma análise dos padrões atípicos.

Anexos

Anexo 1

```
|-- song_id: string (nullable = true)
|-- performer: string (nullable = true)
|-- song: string (nullable = true)
|-- spotify_genre: string (nullable = true)
|-- spotify_track_id: string (nullable = true)
|-- spotify_track_preview_url: string (nullable = true)
|-- spotify_track_duration_ms: string (nullable = true)
|-- spotify_track_explicit: string (nullable = true)
|-- spotify_track_album: string (nullable = true)
|-- danceability: string (nullable = true)
|-- energy: string (nullable = true)
|-- key: string (nullable = true)
|-- loudness: string (nullable = true)
|-- mode: string (nullable = true)
|-- speechiness: string (nullable = true)
|-- acousticness: string (nullable = true)
|-- instrumentalness: string (nullable = true)
|-- liveness: string (nullable = true)
|-- valence: string (nullable = true)
|-- tempo: string (nullable = true)
|-- time_signature: string (nullable = true)
|-- spotify_track_popularity: string (nullable = true)
```

Anexo 2

```
|-- url: string (nullable = true)
|-- week_id: string (nullable = true)
|-- week_position: integer (nullable = true)
|-- song: string (nullable = true)
|-- performer: string (nullable = true)
|-- song_id: string (nullable = true)
|-- instance: string (nullable = true)
|-- previous_week_position: string (nullable = true)
|-- peak_position: string (nullable = true)
|-- weeks_on_chart: string (nullable = true)
```