



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Padrões de Sucesso Musical no Billboard Hot 100: Uma Análise Não Supervisionada com PCA e K-Means

André Soares, aluno n.º 98306

António Navalhas, aluno n.º 108187

Lifan Chen, aluno n.º 136520

Pedro Lourenço, aluno n.º 133931

Mestrado: Ciência de Dados

Unidade curricular: Processamento e Modelação de Big Data

Professor Auxiliar Alexandre Passos de Almeida,
ISCTE – Instituto Universitário de Lisboa

Índice

1. Introdução	3
2. Preparação Final Dos Dados.....	4
2.1 Leitura dos ficheiros e limpeza inicial dos dados	4
2.2 Agregação longitudinal e criação de variáveis analíticas	4
2.3 Integração de dados e tratamento dos valores em falta	5
2.4 Seleção de Features	5
3. Metodologia.....	6
4. Resultados.....	6
4.1 Redução da Dimensionalidade (PCA) e Escolha do Modelo.....	6
4.2 Caracterização dos Clusters	7
4.3 Identificação de Comportamentos Atípicos	8
4.4 Perguntas de Investigação.....	8
5. Discussão	9
5.1 Interpretação Crítica e Validade Musical dos Clusters	9
5.2 Expectativas Fase 1 vs Resultados	9
5.3 Dinâmicas de Sucesso: Êxitos Imediatos vs. Slow Burners	10
5.4 Músicas Sonoramente Atípicas e o Fenómeno Sazonal	10
5.5 Clusters Difíceis de Interpretar	10
5.6 Limitações do Estudo, do Método e dos Dados	10
6. Conclusões	11
7. Uso de IA	12
8. Referências.....	13
9. Anexos.....	14
Anexo 1 – Variância Explicada por cada componente	14
Anexo 2 - Avaliação do Número de Clusters pelo Silhouette Score e Inertia	14
Anexo 3 – Dimensão dos Clusters.....	15
Anexo 4 - Distribuição das Músicas por Cluster	15
Anexo 5 - Exemplos Representativos de Músicas por Cluster	16
Anexo 6 - Top 20 Observações Atípicas segundo Distância ao Centróide.....	16

1. Introdução

O presente projeto tem como base o *dataset Billboard Hot 100*, relativo ao *ranking* semanal das músicas mais populares nos Estados Unidos. Este *ranking* constitui uma referência central na indústria musical, uma vez que reflete o desempenho comercial das músicas através de indicadores como vendas, reprodução em rádio e *streaming*. Pela sua natureza temporal e pela variedade de informação disponível, este conjunto de dados permite analisar diferentes padrões de sucesso musical, tanto ao nível da trajetória das músicas no *ranking* como das suas características sonoras.

A análise utiliza dois ficheiros principais. O ficheiro *billboard.csv* contém a evolução semanal das músicas no *ranking*, incluindo variáveis como a semana da observação, a posição ocupada, a posição anterior, a melhor posição atingida e o número de semanas no *top*. Por outro lado, o ficheiro *audio_features.csv* inclui características musicais extraídas do *Spotify*, como *danceability*, *energy*, tempo, *valence*, *acousticness*, *loudness* e popularidade da faixa. A combinação destes dois ficheiros permite relacionar o desempenho das músicas no *ranking* com os seus atributos musicais.

Na Fase 1 do projeto foi realizada uma análise exploratória inicial, onde se identificaram a estrutura dos dados, os principais problemas de qualidade, a existência de valores em falta representados por "NA", duplicados no ficheiro de características de áudio e a necessidade de corrigir tipos de dados. Foram também propostas questões de investigação orientadas para a descoberta de padrões através de métodos de aprendizagem não supervisionada. O objetivo geral da Fase 2 é concretizar essa análise, preparando os dados de forma adequada, criando variáveis representativas da trajetória das músicas no *ranking* e aplicando métodos de aprendizagem não supervisionada, nomeadamente PCA e K-Means, para identificar perfis distintos de sucesso musical.

As perguntas de investigação finais são:

- É possível reduzir a dimensionalidade das variáveis musicais e de desempenho sem perder informação relevante?
- Existem grupos homogêneos de músicas com base nas suas características sonoras e trajetória no *ranking*?
- Que tipos de padrões de sucesso musical podem ser identificados, como êxitos imediatos, músicas de longa permanência ou músicas com pico curto?
- Existem músicas com comportamento particularmente atípico face aos restantes grupos?

A unidade de análise adotada é a música, identificada pela variável *song_id*. Como o ficheiro *billboard.csv* contém várias observações semanais para a mesma música, os dados foram agregados por *song_id*, permitindo representar cada música através de um único conjunto de variáveis de desempenho e características de áudio.

2. Preparação Final Dos Dados

2.1 Leitura dos ficheiros e limpeza inicial dos dados

A preparação dos dados foi iniciada com a leitura dos ficheiros *billboard.csv* e *audio_features.csv* através do *PySpark*. A leitura foi feita sem inferência automática de esquemas (*inferSchema=False*) para evitar erros na conversão de tipos causados pela presença de valores nulos representados como texto.

De seguida, foi aplicado as seguintes transformações de limpeza:

- **Tratamento de valores nulos:** Os valores textuais "NA" e as *strings* vazias foram substituídos por valores *null*;
- **Remoção de valores duplicados:** Foram eliminados os registos duplicados em ambos os conjuntos de dados para garantir a integridade da análise;
- **Conversão de tipos de dados:** As variáveis quantitativas, como posições no *ranking* e características de áudio foram convertidas para o formato *double* para permitir operações matemáticas futuras;
- **Tratamento de datas:** A variável temporal *week_id* foi convertida do formato de texto (M/d/yyyy) para o tipo *Date* (*week_date*), o que possibilitou a extração temporal e ordenações precisas.

2.2 Agregação longitudinal e criação de variáveis analíticas

O *dataset* *billboard.csv* possui uma estrutura longitudinal, onde uma música tem uma linha por cada semana em que esteve no ranking, assim para *clustering*, a unidade de análise passa a ser música. O conjunto de dados foi agregado pela chave da música (*song_id*). Recorrendo a funções de janela (*Window functions*) e agregações globais, o ciclo de vida de cada tema foi sumarizado numa única linha.

De seguida foi criado diversas variáveis analíticas para descrever o sucesso e a trajetória comercial da música:

- ***chart_weeks*:** O número total de semanas que a música permaneceu na tabela;
- ***best_position*:** A melhor classificação que a música teve no *ranking*;
- ***entry_position* e *final_position*:** A posição da música na primeira semana e na última semana no *ranking*;

- ***avg_position***: Média das todas posições da música no *ranking*;
- ***position_volatility***: O desvio padrão das posições semanais, quantifica a instabilidade da música no *ranking*;
- ***top10_share***: Representa a percentagem do tempo total que a música passou nos 10 primeiros lugares face ao tempo total que esteve no *ranking*;
- ***time_to_peak_weeks***: O tempo, medido em semanas, decorrido entre a data de lançamento da música e a data em que atingiu a sua posição mais alta.

2.3 Integração de dados e tratamento dos valores em falta

Após a sumarização do percurso de cada música na tabela *Billboard*, o conjunto de dados resultante foi unido com as características sonoras do ficheiro *audio_features.csv*. Esta integração foi feita através de um *left join* pela chave *song_id*, tendo-se garantido previamente a duplicação do ficheiro de áudio por esta mesma chave. E para lidar com a existência de valores em falta no conjunto final, foi utilizado o *Imputer*. Todos os valores omissos nas variáveis de modelação foram preenchidos através do método da mediana. Optou-se por esta estratégia por ser estatisticamente mais robusta à presença de eventuais *outliers* do que utilizando-se a média.

2.4 Seleção de Features

O principal objetivo na seleção do conjunto final de *features* foi garantir um *dataset* equilibrado. O objetivo foi captar a *performance* comercial da música, variáveis agregadas da *Billboard*, que mostram a longevidade e o sucesso, e a sua "*vibe*" ou estrutura sonora, através das métricas do *Spotify*, como a *danceability*, *energy*, *tempo* e *valence*.

Assim foram selecionadas apenas *features* numéricas contínuas. O uso de algoritmos de aprendizagem não supervisionada baseados em cálculos de distância (PCA e K-Means) exige que os *inputs* sejam dados numéricos contínuos, pelo que apenas as variáveis transformadas e normalizadas foram admitidas.

Foram removidos na conduta de treino todas as variáveis textuais, meta-dados e identificadores, tais como *URLs*, *IDs* do *Spotify*, nomes dos artistas, títulos das músicas e categorizações em texto (ex: *spotify_genre*). Estas variáveis não possuem significado matemático direto que possa ser calculado ou escalado pelo modelo. Estas métricas foram retidas na tabela base apenas com o propósito de identificação e interpretação qualitativa dos exemplos de músicas em cada *cluster* final.

3. Metodologia

Dado que o objetivo do trabalho foi identificar padrões sem uma variável-alvo definida, foi adotada uma abordagem de aprendizagem não supervisionada. Esta opção é adequada ao *dataset Billboard Hot 100*, pois permitiu explorar grupos de músicas com características sonoras e trajetórias semelhantes no ranking.

Foram selecionadas variáveis numéricas de duas dimensões: características áudio do *Spotify*, como *danceability*, *energy*, *valence*, tempo, *loudness* e *spotify_track_popularity*, e variáveis agregadas do desempenho no *ranking*, como *chart_weeks*, *best_position*, *avg_position*, *position_volatility*, *top10_share* e *time_to_peak_weeks*. Antes da modelação, os valores em falta foram tratados por imputação da mediana. De seguida, as variáveis foram normalizadas com *StandardScaler*, uma vez que os métodos utilizados dependem de distâncias e poderiam ser influenciados por variáveis com escalas diferentes.

Foi aplicada Análise de Componentes Principais (PCA) para reduzir a dimensionalidade e sintetizar informação potencialmente redundante, tendo sido utilizadas cinco componentes principais, permitindo representar as músicas num espaço mais compacto antes da aplicação do *clustering*.

Para a criação dos grupos foi utilizado o algoritmo *K-Means*, adequado a dados numéricos normalizados. Foi definida uma semente aleatória fixa (*RANDOM_SEED = 42*) para garantir reprodutibilidade, e o número máximo de iterações foi fixado em 50. A escolha do número de *clusters* foi sustentada pela comparação de vários valores de *k*, entre 2 e 8. As soluções foram avaliadas com base na *silhouette*, que mede a separação e coesão dos grupos, e na *inertia*, que avalia a compactação interna. A solução final escolhida foi *k = 4*, por apresentar o melhor valor de *silhouette* entre as opções testadas.

Por fim, foram identificadas observações potencialmente atípicas através da distância de cada música ao centróide do seu cluster no espaço PCA. As músicas mais afastadas foram consideradas casos com comportamento menos semelhante ao grupo em que foram inseridas.

4. Resultados

4.1 Redução da Dimensionalidade (PCA) e Escolha do Modelo

Após a aplicação da Análise de Componentes Principais (PCA), foi possível reduzir significativamente a dimensionalidade da amostra, condensando a complexidade do conjunto de dados que funde métricas de áudio do *Spotify* e trajetórias históricas da *Billboard*. Desta forma, extraíram-se cinco componentes principais, retendo-se 51.76% da variância total dos dados originais, conforme o Anexo 1. Embora este valor indique que cerca de metade da informação se tenha perdido no processo de compressão, a primeira componente destaca-se

isoladamente ao capturar 18.26% da informação estrutural. Esta redução, ainda que pesada, foi fulcral para limpar o ruído estatístico e preparar a amostra para a aplicação da técnica de clusterização.

Efetuando-se a avaliação de diferentes partições de k , de 2 a 8, através do algoritmo K-Means, demonstrou-se um comportamento claro nos indicadores estatísticos, pois o valor de $k = 2$ revelou-se a escolha ideal ao alcançar um Silhouette Score robusto de 0.8041, conforme Anexo 2. À medida que se aumentou o número de grupos para três ou quatro, a coesão interna desceu para valores em torno de 0.62 e 0.54, conforme Anexo 2, respetivamente, enquanto que a Inertia, i.e. o custo de treino decresceu de forma linear. Assim, concluiu-se que o algoritmo provou que a estrutura subjacente à indústria musical é fundamentalmente binário, dividindo-se de forma clara em dois grandes blocos, ao invés de múltiplos nichos.

4.2 Caracterização dos Clusters

De seguida, após aplica a técnica de segmentação por cluster, concluiu-se que o agrupamento final resultou numa distribuição fortemente assimétrica, isolando uma vasta maioria de um segmento muito específico de canções. O Cluster 0, denominado por "Macrospectro do Mainstream Melódico e de Longa Duração", engloba a esmagadora maioria do dataset, contendo vinte e seis mil setecentas e quatro músicas, conforme Anexo 3. Este cluster define-se pela norma histórica das tabelas de sucesso, caracterizando-se por valores moderados e equilibrados de dançabilidade (0.604) e de energia (0.593), conforme Anexo 4. O seu grande diferencial foca-se no desempenho de bastidores, pois estas músicas entram na tabela numa posição média ligeiramente mais confortável (80.2) e alcançam um pico médio consideravelmente superior (46.35), conforme Anexo 4. Por fim, foi possível concluir que este cluster, revelou ser o verdadeiro motor de longevidade nas tabelas, apresentando uma taxa de permanência no Top 10 (top10_share de 5.4% conforme Anexo 4), superando o Cluster 1. Exemplos de músicas deste cluster são, “Radioactive” dos Imagine Dragons com um índice de permanência nas tabelas por um período de 87 semanas, “Sail” dos AWOLNATION, “Blinding Lights” do The Weeknd e, “How Do I Live” de LeAnn Rimes.

Por outro lado, o Cluster 1, denominado como "Hinos Rítmicos de Alta Energia Circunstancial", revelou destacar-se por conter um nicho hiper-específico com apenas mil cento e noventa e nove músicas, conforme Anexo 2. Sonoramente, este cluster destaca-se pela sua a dançabilidade, que aumentou para 0.706, a energia com 0.746 e, a valência, i.e., a assinatura de positividade musical, fixada nos 0.740, conforme Anexo 3. Porém, os dados demonstraram que esta intensidade sonora não se traduziu linearmente numa performance histórica na tabela Billboard, uma vez que em média, estas músicas entram mais abaixo no ranking (85.39), têm picos mais modestos (53.73) e a sua quota de permanência no Top 10 cai para os 3.1%, conforme Anexo 4. Este perfil de música, caracteriza o cluster 1 como detentor de canções de grande impacto imediato, que dominam a opinião do público,

mas que têm ciclos de vida comercial ligeiramente mais restritos, como “Sicko Mode” de Travis Scott, “That's What I Like” de Bruno Mars, “Thrift Shop” de Macklemore e “Watch Me” de Silento.

4.3 Identificação de Comportamentos Atípicos

Depois de efetuada a análise de anomalias, feita através do cálculo da distância euclidiana de cada faixa ao centroide do seu respetivo cluster no espaço geométrico da PCA, destacaram-se dois pontos a ter em conta. Por um lado, encontrou-se a permanência de anomalias severas e dados rudimentares no Cluster 1, onde faixas históricas antigas como “Over The Mountain”; “Across The Sea” de Johnnie & Joe e “Ain't Got No”; “I Got Life” de Nina Simone registaram grandes distâncias, 66.312 e 45.044, respetivamente conforme Anexo 6. Este isolamento extremo justificou-se pelo facto de se combinarem a assinatura sonora enérgica do Cluster 1 com uma presença rápida e volátil nas tabelas, com permanências curtas de duas a quatro semanas no fundo do ranking, o que contrastou com a estabilidade dos líderes desse cluster.

Por outro lado, foi também detetado no Cluster 0, questões de sazonalidade cultural. Os maiores outliers deste grupo não demonstraram ser canções com sonoridades estranhas, mas sim os clássicos imortais de Natal, como “Rockin' Around The Christmas Tree” de Brenda Lee, “Jingle Bell Rock” de Bobby Helms e “All I Want For Christmas Is You” de Mariah Carey. Estas canções demonstraram distâncias elevadas face ao centroide devido ao seu comportamento atípico nas tabelas, quebrando totalmente a linearidade do ciclo de vida de um êxito comum, que se caracteriza pela sua entrada, atingimento do pico e desaparecimento para sempre. Em vez disso, estas canções registam picos de popularidade elevados (posições 1, 2 ou 3) combinados com uma grande volatilidade de posição (superior a 15.9), entrando e saindo de forma cíclica e agressiva todos os anos em dezembro, o que baralha as métricas de trajetória do K-Means.

4.4 Perguntas de Investigação

Assim, após a aplicação de técnicas de redução da dimensionalidade, e consequentemente segmentação em clusters, foi possível concluir o seguinte, face às perguntas colocadas como ponto de partida da análise:

Pergunta 1 – Sim, a aplicação da técnica da PCA conseguiu achatar dezenas de métricas complexas e temporais para apenas cinco eixos fundamentais. Embora a perda de quase metade da variância original, 48.24% respetivamente, sinalize que nuances artísticas mais finas foram sacrificadas, o volume de informação preservado, 51.76% respetivamente, provou ser perfeitamente suficiente e focado para permitir uma separação matemática limpa e altamente fiável entre os perfis macro da indústria musical.

Pergunta 2 – Sim, os dados confirmaram a existência de agrupamentos homogéneos, mas revelam que o ecossistema musical se organiza numa lógica polarizada. Em vez de se encontrar uma fragmentação em múltiplos géneros ou subgéneros, o mercado divide-se em dois grandes blocos coesos, uma massiva corrente normativa de

canções com dinâmicas moderadas e passos firmes na tabela (Cluster 0), e um grupo compacto de faixas de alta volatilidade rítmica com carreiras comerciais mais efêmeras (Cluster 1).

Pergunta 3 – O modelo isolou o padrão de longa permanência e os chamados *slow burners* maioritariamente no Cluster 0, enquanto que músicas com dinâmicas sonoras menos cansativas conseguiram fixar-se nas tabelas durante perto de setenta ou oitenta semanas, capitalizando uma presença sustentada no Top 10. Para além disto, o tempo médio para atingir o pico é idêntico em ambos os grupos, cerca de 6.7 semanas, o que sugere que a velocidade de ascensão de um hit é uma constante de mercado, mas as faixas enérgicas do Cluster 1 sofrem de um pico mais curto, perdendo popularidade mais depressa após o impacto inicial.

Pergunta 4 – Sim, o algoritmo provou que o comportamento mais atípico na história das tabelas norte-americanas pertence ao fenómeno da sazonalidade natalícia. Músicas como as de Mariah Carey e Brenda Lee operam fora dos padrões normais, gerando anomalias de trajetória que o K-Means identificou como outliers devido à sua natureza cíclica e reentradas anuais massivas.

5. Discussão

5.1 Interpretação Crítica e Validade Musical dos Clusters

Numa primeira observação, a segmentação dos dados em apenas dois grupos ($k=2$), demonstrou ser redutora face à vasta diversidade de géneros musicais presentes na tabela da Billboard. Contudo, do ponto de vista do consumo de massa, esta divisão demonstrou coesão dado que o algoritmo ignorou os rótulos convencionais de "género" e focou-se na biomecânica das canções, dividindo o mercado num extremo de dois polos. Um contendo a música orientada para a audição passiva e melódica (Cluster 0) e, outro contendo a música orientada para a resposta física e pista de dança (Cluster 1). O facto de canções caracterizadas por uma alta valência, energia e dançabilidade terem sido isoladas no Cluster 1 prova que a arquitetura sonora destas músicas força um padrão de consumo distinto. As mesmas, acabam por criar um impacto físico e cultural forte, mas comportam-se como um nicho concentrado, face ao vasto oceano da música pop/rock normativa do Cluster 0.

5.2 Expectativas Fase 1 vs Resultados

Na Fase 1 do projeto, definiu-se como objetivo primordial agrupar as variáveis musicais em grupos homogêneos pelo seu som, utilizando a PCA para reduzir a dimensionalidade das catorze variáveis numéricas presentes no ficheiro `audio_features.csv`. Face aos resultados obtidos, confirmou-se esta premissa metodológica, comprovando que a PCA e o K-Means são ferramentas eficazes para sintetizar e estruturar este ecossistema. Contudo, registou-se um ajuste metodológico pertinente na abordagem aos outliers, pois enquanto na proposta inicial se sugeriu a utilização do algoritmo Isolation Forest para efetuar cortes lógicos e isolar músicas atípicas, na presente fase concluiu-se que o cálculo direto da distância euclidiana de cada faixa ao centroide do seu cluster

respondia de forma robusta e simplificada à questão sobre a existência de músicas verdadeiramente únicas no Top 100.

5.3 Dinâmicas de Sucesso: Êxitos Imediatos vs. Slow Burners

Outro dos objetivos centrais delineados na Fase 1 era compreender como se comportam as músicas ao longo do tempo, procurando padrões claros entre hits imediatos e *slow burners*. A análise temporal aos dois clusters validou esta dicotomia existencial, visto que o Cluster 1 apresentou-se como o epicentro dos êxitos imediatos e das músicas com pico curto. Temas intensamente rítmicos tendem a gerar picos de consumo explosivos, mas a sua alta energia causa uma fadiga auditiva mais rápida, resultando numa permanência menor no Top 10 e saídas mais prematuras da tabela. Em contrapartida, o Cluster 0 demonstrou-se como sendo o domínio absoluto das músicas de longa permanência e dos verdadeiros *slow burners*. Ao apresentar níveis de energia mais moderados, estas canções são *user friendly* para consumo contínuo e não cansam o ouvinte, permitindo-lhes crescer lentamente e sustentar uma longevidade nas tabelas.

5.4 Músicas Sonoramente Atípicas e o Fenómeno Sazonal

Quanto à discussão sobre casos atípicos, concluiu-se que uma verdadeira anomalia nem sempre é sonora, mas sim comportamental. O modelo identificou clássicos de Natal como os maiores *outliers* do *dataset*. Sonoramente, estas faixas pertencem ao mainstream harmónico do Cluster 0, mas o seu padrão de reentrada explosiva a cada dezembro destrói as métricas de agressividade de posição, ilustrando como o consumo sazonal opera sob leis temporais totalmente distintas do ciclo pop normal avaliado longitudinalmente no ficheiro *billboard.csv*.

5.5 Clusters Difíceis de Interpretar

Apesar da coesão alcançada, o Cluster 0 apresenta-se como o mais difícil de interpretar devido à sua magnitude colossal, englobando cerca de 95% dos dados. Ao funcionar como um macrogrupo normativo, este cluster abriga realidades musicais excessivamente díspares. Colocar no mesmo patamar estrutural baladas acústicas dos anos 60 e *synth-pop* dos anos 80 significa que tendências mais finas ficaram soterradas nesta categoria, tornando difícil extrair regras precisas sobre o que define o sucesso neste grupo, pois ele representa, na prática, todo o espectro que não pertence ao Cluster 1.

5.6 Limitações do Estudo, do Método e dos Dados

Em primeiro lugar, ao nível dos dados, ao se cruzar o ficheiro *billboard.csv* que reflete desempenhos históricos longitudinais, com características de áudio contemporâneas extraídas do Spotify, misturando épocas onde o sucesso era medido por reprodução de rádio e vendas físicas com a atual era do *streaming*, conclui-se que

pode ter sido gerado alguns anacronismos. Ao nível da preparação dos dados, a necessidade de colmatar a elevada presença de valores nulos e estruturais através da imputação por mediana encolheu artificialmente a variância natural de algumas métricas. Relativamente ao processo de agregação por música, este comprimiu a evolução longitudinal rica da tabela numa única média, perdendo a evolução de cada entrada e saída semanal. Por fim, as limitações do K-Means impuseram uma divisão euclidiana estrita, forçando músicas que fundem géneros como o pop-rap, a pertencerem em absoluto a um único grupo, ignorando a natureza contínua e interligada da música comercial.

6. Conclusões

A análise realizada permitiu concretizar os objetivos definidos na Fase 1, aplicando métodos de aprendizagem não supervisionada ao *dataset* Billboard Hot 100. Através da preparação dos dados, da agregação das observações por música e da junção entre métricas de desempenho na Billboard e características áudio do Spotify, foi possível construir uma base adequada à identificação de padrões de sucesso musical.

Os principais resultados mostram que a PCA permitiu reduzir a dimensionalidade dos dados para cinco componentes principais, retendo 51,76% da variância total. Esta redução tornou possível aplicar o K-Means de forma mais eficiente, tendo a avaliação entre diferentes valores de k indicado a solução com dois clusters como a mais adequada, com um Silhouette Score de 0,8041. A segmentação obtida revelou uma divisão clara entre um grande grupo dominante de músicas com características mais moderadas e trajetórias de maior permanência, e um grupo menor de faixas mais energéticas, dançáveis e positivas, mas com desempenho médio mais curto nas tabelas.

A análise contribuiu para uma melhor compreensão do *dataset* ao mostrar que o sucesso musical não depende apenas da melhor posição atingida no ranking. A permanência na tabela, a posição média, a volatilidade, a presença no Top 10 e as características sonoras revelaram-se dimensões importantes para distinguir diferentes padrões de comportamento. Também se verificou que os casos mais atípicos não são necessariamente músicas sonoramente estranhas, mas sim faixas com trajetórias excecionais, como os clássicos natalícios, cujo comportamento sazonal se afasta do ciclo habitual de entrada, pico e desaparecimento do *ranking*.

Apesar dos resultados obtidos, o estudo apresenta algumas limitações. A combinação de dados históricos da Billboard com características de áudio recolhidas no contexto do Spotify pode introduzir diferenças entre épocas musicais distintas. Além disso, a imputação por mediana pode reduzir parte da variabilidade original dos

dados, e a agregação por música simplifica a evolução semanal das faixas, levando à perda de algum detalhe temporal. Por fim, o K-Means impõe uma separação rígida entre grupos e pode não captar totalmente a natureza contínua e híbrida da música comercial.

Como extensões futuras, seria relevante testar outros métodos de clustering capazes de captar estruturas mais complexas, aprofundar a análise temporal das reentradas e saídas do ranking, comparar os clusters com géneros musicais e aplicar métodos específicos de deteção de anomalias, como *Isolation Forest*. Ainda assim, a análise realizada permitiu responder às perguntas de investigação e identificar padrões interpretáveis sobre diferentes formas de sucesso musical no Billboard Hot 100.

7. Uso de IA

No desenvolvimento deste trabalho foram utilizadas ferramentas de Inteligência Artificial generativa, nomeadamente o ChatGPT/Codex, como apoio complementar. A sua utilização foi limitada a tarefas de apoio, não substituindo a análise crítica nem a responsabilidade dos elementos do grupo

A IA foi usada para apoiar a estruturação do relatório, a reformulação textual, a revisão linguística, o esclarecimento conceptual sobre aprendizagem não supervisionada e a organização do código em *PySpark*. Também auxiliou na documentação de funções e na forma de apresentar resultados de PCA, *K-Means* e observações atípicas.

Todas as sugestões foram revistas criticamente pelo grupo. O código foi executado e validado pelos autores, os resultados foram analisados com base nos outputs obtidos e as interpretações foram discutidas e ajustadas pelos elementos do grupo.

A integridade académica foi assegurada através da validação humana dos conteúdos, da adaptação das sugestões ao *dataset* analisado e da garantia de que o grupo compreende e consegue explicar o código, os métodos aplicados e as conclusões apresentadas.

8. Referências

Apache Software Foundation. (n.d.). Clustering - MLlib. Apache Spark Documentation. Retrieved May 28, 2026, from <https://spark.apache.org/docs/latest/mllib-clustering.html>

Apache Software Foundation. (n.d.). PCA - PySpark documentation. Apache Spark Documentation. Retrieved May 28, 2026, from <https://spark.apache.org/docs/latest/api/python/reference/api/pyspark.ml.feature.PCA.html>

Apache Software Foundation. (n.d.). StandardScaler - PySpark documentation. Apache Spark Documentation. Retrieved May 28, 2026, from <https://spark.apache.org/docs/latest/api/python/reference/api/pyspark.ml.feature.StandardScaler.html>

Apache Software Foundation. (n.d.). Imputer - PySpark documentation. Apache Spark Documentation. Retrieved May 28, 2026, from <https://spark.apache.org/docs/latest/api/python/reference/api/pyspark.ml.feature.Imputer.html>

Billboard. (n.d.). Billboard Hot 100. Retrieved May 28, 2026, from <https://www.billboard.com/charts/hot-100/>

Jolliffe, I. T., & Cadima, J. (2016). Principal component analysis: A review and recent developments. Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences, 374(2065), Article 20150202. <https://doi.org/10.1098/rsta.2015.0202>

MacQueen, J. (1967). Some methods for classification and analysis of multivariate observations. In L. M. Le Cam & J. Neyman (Eds.), Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability (Vol. 1, pp. 281-297). University of California Press.

R4DS Online Learning Community. (2021, September 14). Top 100 Billboard [Data set]. TidyTuesday. <https://rfordatascience.github.io/tidyuesday/data/2021/2021-09-14/readme.html>

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53-65. [https://doi.org/10.1016/0377-0427\(87\)90125-7](https://doi.org/10.1016/0377-0427(87)90125-7)

9. Anexos

Anexo 1 – Variância Explicada por cada componente

Variancia explicada por componente:

PC1: 0.1826

PC2: 0.1055

PC3: 0.0822

PC4: 0.0812

PC5: 0.0660

Total explicado pelas 5 componentes: 0.5176

Anexo 2 - Avaliação do Número de Clusters pelo Silhouette Score e Inertia

k=2: silhouette=0.8041; inertia=371732.51

k=3: silhouette=0.6205; inertia=282983.85

k=4: silhouette=0.5450; inertia=193856.30

k=5: silhouette=0.5547; inertia=149433.96

k=6: silhouette=0.4555; inertia=126638.81

k=7: silhouette=0.5409; inertia=92501.82

k=8: silhouette=0.5681; inertia=84039.97

Melhor k por silhouette: 2 (0.8041)

Resumo dos valores testados:

k		silhouette		inertia
---	--	------------	--	---------

2		0.8041		371732.51
---	--	--------	--	-----------

3		0.6205		282983.85
---	--	--------	--	-----------

4		0.5450		193856.30
---	--	--------	--	-----------

5		0.5547		149433.96
---	--	--------	--	-----------

6		0.4555		126638.81
---	--	--------	--	-----------

7		0.5409		92501.82
---	--	--------	--	----------

8		0.5681		84039.97
---	--	--------	--	----------

Anexo 3 – Dimensão dos Clusters

Dimensao dos clusters:

prediction	count
0	26704
1	1199

Anexo 4 - Distribuição das Músicas por Cluster

TABELA DE CENTROIDES DOS CLUSTERS (MÉDIAS)													
prediction	chart_weeks	best_position	avg_position	position_volatility	entry_position	final_position	top10_share	time_to_peak_weeks	danceability	energy	valence	tempo	spotify_track_popularity
0	11.77	46.351	61.757	15.61	80.214	76.308	0.054	6.741	0.604	0.593	0.678	118.077	0.03
1	11.328	53.734	68.467	13.937	85.393	85.157	0.031	6.758	0.706	0.746	0.74	119.789	0.031

ANÁLISE DE TRACKS POR CLUSTER: EXEMPLOS REPRESENTATIVOS



CLUSTER 0: MAINSTREAM MELÓDICO E LONGA DURAÇÃO

% prediction	🎵 song	👤 performer	📊 chart_weeks	🏆 best_position	📊 avg_position	📈 top10_share
0	NULL	NULL	16333.0	46.0	64.0	0.0
0	Radioactive	Imagine Dragons	87.0	3.0	32.82	0.23
0	Sail	AWOLNATION	79.0	17.0	50.41	0.0
0	Blinking Lights	The Weeknd	76.0	1.0	9.95	0.75
0	I'm Yours	Jason Mraz	76.0	6.0	29.51	0.171
0	How Do I Live	LeAnn Rimes	69.0	2.0	19.62	0.464
0	Party Rock Anthem	LMFAO Featuring Lauren Bennett & GoonRock	68.0	1.0	22.31	0.426
0	Counting Stars	OneRepublic	68.0	2.0	26.31	0.368

CLUSTER 1: HINOS RÍTMICOS E ALTA ENERGIA

1	Sicko Mode	Travis Scott	52.0	1.0	16.21	0.615
1	That's What I Like	Bruno Mars	51.0	1.0	18.06	0.549
1	Watch Me	Silento	51.0	3.0	24.75	0.353
1	Believer	Imagine Dragons	51.0	4.0	23.9	0.275
1	Thunder	Imagine Dragons	51.0	4.0	34.65	0.333
1	Thrift Shop	Macklemore & Ryan Lewis Featuring Wanz	49.0	1.0	22.98	0.429
1	It's Time	Imagine Dragons	47.0	15.0	42.81	0.0
1	Whomp! (There It Is)	Tag Team	45.0	2.0	14.78	0.533

Track (Performer)	Prediction (GRP 0/1)	Distance to Centroid	Chart Weeks	Best Position	Position Volatility
Over The Mountain; Across The Sea Johnnie & Joe	GRP 0	66312.527	223	1.0	30.877
Diplo Presents Thomas Wesley Featuring Morgan Wallen Heartless	GRP 1	45044.212	203	1.0	28.938
Nina Simone Nina Simone	GRP 0	42623.675	217	1.0	29.955
The Ree Mariah Carey	GRP 0	42168.223	181	1.0	29.317
Travis Scott Bruno Mars	GRP 0	39695.653	109	1.0	36.177
Bruno Mars Bruno Mars	GRP 0	30373.387	169	1.0	37.409
DMX Michael Jackson	GRP 1	30381.820	233	1.0	29.955
Michael Jackson Mariah Carey	GRP 0	29558.576	280	1.0	28.343
FloE Me Big Httot	GRP 0	23614.984	213	1.0	36.177
Take My Sand Johnnie & Joe	GRP 0	18830.336	129	1.0	29.955
The Mon Travis Scott	GRP 1	48653.584	105	1.0	36.177
Heartless Bruno Mars	GRP 1	59168.535	101	1.0	30.585
Michael Jackson Bruno Mars	GRP 1	68383.792	99	1.0	31.938
Travis Scott Michael Jackson	GRP 1	49394.502	82	1.0	20.837
Michael Jackson Bruno Mars	GRP 1	47789.327	33	1.0	29.955
Michael Jackson Travis Scott	GRP 1	46163.578	79	1.0	36.177
DMX Nina Simone	GRP 1	45044.212	35	1.0	29.955

* Analysis based on Song Trajectory & Centroid Distance Metrics.

