



INSTITUTO
UNIVERSITÁRIO
DE LISBOA

Estudo Comparativo de Métodos de Classificação de Sentimento em Dados Textuais

André Soares, aluno n.º 98306
António Navalhas, aluno n.º 108187
Lifan Chen, aluno n.º 136520
Pedro Lourenço, aluno n.º 133931

Mestrado: Ciência de Dados

Unidade curricular: Text Mining para Ciência de Dados

Professores Fernando Batista e Ricardo Ribeiro
ISCTE – Instituto Universitário de Lisboa

Abril 2026

Índice

Resumo	3
Introdução	4
Revisão da Literatura.....	4
1. Dados Utilizados.....	7
2. Limpeza e Pré-Processamento dos Dados.....	7
3. Metodologia de trabalho	9
3.1 Aplicação de Modelos existentes aos Dados de teste	9
3.1.1 Modelos baseados em Léxicos e Regras.....	9
3.1.2 Modelos baseados em Transformadores	9
3.1.3 Comparação dos Modelos	10
3.2 Aplicação de Léxico de sentimentos	10
3.2.1 Pré-processamento dos léxicos	10
3.2.2 Criação de classificador de análise de sentimentos baseado no léxico NCR-lexicon.csv e opinion_lexicon.csv	11
3.3 Treino de modelos de aprendizagem automática	13
3.3.1 Métodos de classificação automática	14
3.3.2 Fine-tuning de modelo pré-treinado baseado em transformadores (DistilBERT)	15
3.3.3 Comparação e síntese dos resultados:	16
3.4 Análise de sentimentos do texto com AI.....	17
4. Discussão dos Resultados.....	18
4.1 Comparação entre modelos baseados em léxico e transformadores	18
4.2 Comparação de resultados entre o classificador com tratamento e sem tratamento	19
4.3 Comparação de modelos de aprendizagem automática	19
Conclusão	20
Bibliografia.....	21
Anexos	24
Review 1: Sentimento Negativo / Decepcionado	25
Review 2: Sentimento Positivo / Entusiasta	25

Resumo

Este estudo avalia e compara o desempenho de diferentes abordagens para a realização da técnica de análise de sentimentos, englobando modelos baseados em léxico, com e sem tratamento de negação; algoritmos clássicos de aprendizagem automática; modelos baseados em transformadores (DistilBERT) e a utilização de Inteligência Artificial generativa. Desta forma, os resultados demonstram uma clara superioridade dos modelos clássicos supervisionados face às abordagens baseadas em léxico e regras. A Regressão Logística, suportada por representação TF-IDF com bigramas, obteve o melhor desempenho global ($F1\text{-score} = 0,8946$), seguida pelo SVM. Verificou-se, também, que a introdução do tratamento de negação nos modelos de léxico não se traduziu em melhorias quantitativas consistentes, enquanto que, o seu desempenho após *fine-tuning* apresentou limitações devido a restrições computacionais que exigiram uma amostra de treino mais reduzida, ficando por isso abaixo dos modelos clássicos. Adicionalmente, a utilização do agente Gemini revelou uma excelente sensibilidade para a classificação textual qualitativa, demonstrando que a capacidade analítica e a precisão das justificações geradas aumentam progressivamente consoante a especificidade do contexto e a inclusão de exemplos fornecidos na *prompt*. Conclui-se que, no contexto analisado e sob restrições de recursos, os modelos clássicos de aprendizagem automática oferecem a relação mais favorável e eficiente entre eficácia preditiva e custo computacional, enquanto as ferramentas de IA generativa se destacam pelo seu elevado potencial interpretativo e de contextualização semântica.

Quanto à percentagem de contribuição de cada elemento, é justo dar 25% de contribuição a cada elemento do grupo, dado que cada um se focou numa abordagem diferente, e foram sempre feitas *code reviews*, de forma a que todos pudessem participar em todas as fases do trabalho e contribuir.

Introdução

O presente trabalho, desenvolvido no âmbito da unidade curricular Text Mining para Ciência de Dados, tem como objetivo a utilização de um *Dataset* baseado em *reviews* feitas a filmes na plataforma *IMDb*, para a realização da tarefa de Análise de Sentimentos. No âmbito de text mining, a análise de sentimentos, trata-se de uma técnica que recorre a processamento de linguagem natural (NLP), com o intuito de identificar, extrair e quantificar estados emocionais e informações subjetivas em categorias como positiva, negativa ou neutra.

Para a aplicação desta técnica, é possível recorrer a dois métodos: um baseado na aplicação de léxico de sentimentos, que recorre a dicionários de palavras pré-classificadas como positivas e negativas, e ao ser aplicado a um novo conjunto de dados percorre palavra a palavra o texto, atribuindo classificações e efetuando uma ponderação final; e um baseado na aplicação de algoritmos de aprendizagem automática, que recorre à aplicação

de algoritmos como *Naive Bayes*, *Support Vector Machines* (SVM) ou *Deep Learning*, algoritmos estes contendo milhares de exemplos de textos previamente classificados por humanos e que por isso, mais facilmente tornam a tarefa de identificar o sentimento associado a cada texto.

Em contexto de *Big Data*, dada a conjuntura atual, na qual as grandes empresas recebem e processam milhares de milhões de dados diariamente, a técnica de análise de sentimentos apresenta-se como sendo uma técnica crucial para o sucesso das mesmas. Com esta, torna-se possível monitorizar a imagem da marca, sendo possível fazer uma rápida análise da mesma numa rede social e perceber qual a perceção dos consumidores; analisar as reclamações de clientes, de forma a rapidamente priorizar clientes com reclamações mais negativas; ou perceber numa análise de mercado, porque é que os consumidores preferem um produto concorrente, entre outras.

Assim, recorrendo a vários métodos para a aplicação desta técnica, o objetivo deste trabalho é comparar os benefícios e as limitações de cada uma, para a tarefa supramencionada, i.e., a aplicação da análise de sentimentos ao *Dataset* contendo *reviews* do *IMDb*.

Revisão da Literatura

De forma a aprofundar os conhecimentos sobre o tema em análise, começou por se realizar uma revisão à literatura existente, com foco nos temas a serem abordados na realização do trabalho. Neste sentido, encontra-se de seguida, uma análise a um conjunto de oito artigos científicos, onde é explicada a metodologia utilizada, os dados em estudo e os resultados obtidos, gerando informação relevante para o tema em questão.

No estudo de Ling (2024), é utilizada uma abordagem focada na aplicação da técnica de *fine-tuning* ao modelo *DistilBERT*, uma versão mais leve e rápida do modelo *BERT* que recorre à aplicação de uma camada densa de classificação sobre o modelo pré-treinado, seguida de um pequeno ajuste aos pesos utilizando uma taxa de aprendizagem reduzida, mantendo desta forma praticamente a totalidade do desempenho do modelo original, mas reduzindo em 40% o número de parâmetros utilizados. Assim, o autor utilizou um conjunto de dados *IMDb Movie Reviews* para a execução da análise de sentimentos, concluindo que “*fine-tuning DistilBERT mitigates the risk of overfitting in smaller datasets by leveraging the rich linguistic representations learned during large-scale pre-training*” (Ling, J., 2024). O autor conseguiu uma *accuracy* comparável a modelos superiores, praticando um tempo de inferência muito menor, reduzindo o consumo de memória e latência, tornando-o ideal para aplicações de ciência de dados em tempo real ou em dispositivos com recursos limitados.

Já Azahree e Alias (2024), procuraram no seu estudo, em fazer uma análise comparativa entre a utilização de modelos baseados em léxicos e regras (VADER) com abordagens que não requerem tanto treino e, técnicas de *deep learning* (LSTM) baseadas em redes neuronais projetadas para capturar o contexto do texto a longo prazo. Assim, recorrendo a um *dataset* com avaliações de filmes foi aplicada a técnica de análise de sentimentos, sendo que antes foi necessário para a aplicação das técnicas de *deep learning*, realizar uma limpeza removendo-se *stop words* e efetuando-se a *tokenização*. Desta forma, os autores concluem que modelos baseados em léxicos e regras são rápidos e eficientes em análises simples, com base em sentimentos claros, mas demonstram dificuldades em perceber a ironia. Por outro lado, com a aplicação de técnicas de *deep learning* os modelos que aprendem o contexto passado são capazes de identificar padrões que regras fixas de léxico ignoram. Assim, os autores reforçam que enquanto o VADER tem um baixo custo computacional, modelos neuronais são mais adequados para maior precisão semântica.

Khoo e Johnkhan (2016), efetuaram uma análise baseada em dicionários através de algoritmos de agregação de pontuações, onde a cada palavra do texto foi feita uma análise quanto à sua polaridade (positiva (1) ou negativa (0)). Desta forma, no seu estudo, os autores demonstraram a importância do pré processamento do texto, especialmente no que toca ao tratamento da negação, pois a *accuracy* tendo a aumentar quando se aplica uma lógica de inversão da polaridade, por exemplo quando o algoritmo encontra um não antes de uma palavra positiva. Para além disso, no seu estudo os autores concluíram que a limpeza dos dados é crucial para garantir uma correspondência exata entre o texto, e os exemplos dados ao classificador.

No seu estudo, Vanitha e Vanathi (2024), procuraram fundir uma abordagem com uso de léxicos com algoritmos de *machine learning*, de forma a serem capazes de melhorar a previsão de sentimentos e ameaças em textos políticos, pois acreditaram que o léxico ajudaria a criar uma base, e o machine learning faria o modelo ser capaz de aprender padrões mais complexos nos dados. Assim, recorrendo a dados de notícias sobre política os autores foram capazes de provar que a utilização de uma abordagem híbrida entre as duas técnicas produz efeitos muito superiores, assim como reforçaram a necessidade do pré-processamento de dados não estruturados quando a aplicação da técnica de análise de sentimentos recai sobre temas complexos como política ou ameaças.

Devin *et al.* (2019), recorreram à utilização de uma abordagem bidirecional, pois focaram-se na aplicação de uma arquitetura *transformer* para que o modelo fosse capaz de ler frases inteiras em ambas as direções ao mesmo tempo, e no fim adicionaram apenas uma camada na fase de *fine-tuning* para efetuar tarefas específicas, como a análise de sentimentos. Assim, utilizando um vasto conjunto de dados da Wikipedia e do BooksCorpus, os autores demonstraram que a arquitetura em questão é capaz de superar as limitações dos modelos clássicos e,

a bidirecionalidade demonstrou ser a chave para o sucesso, dado que para um modelo entender o que vem antes e depois de uma palavra muda a sua precisão de análise.

No seu estudo, González-Carvajal e Garrido-Merchán (2023), o objetivo foi quantificar o aumento da *performance* na utilização de abordagens tradicionais como *TD-IDF* com algoritmos como *SVM*, face à utilização do modelo *BERT* com um processo simples de *fine-tuning*, no que o toca à análise de sentimentos. Assim, os autores recorreram à utilização de vários *datasets* de análise de sentimentos, e inclusive fizeram a comparação dado que o *BERT* demonstrou ser capaz de lidar com o texto quase em bruto sem necessidade um grande pré-processamento. Os autores concluíram que “*the results show that BERT outperforms all the traditional machine learning algorithms (...) this is due to its ability to understand the context of the words in a sentence*” (González-Carvajal, S., & Garrido-Merchán, E. C., 2020). Desta forma para aplicações mais modernas, a aplicação do *BERT*, ainda que exija maior poder de processamento, é justificada pelo aumento da precisão nos resultados.

Rathore, A. J. S. *et al.* (2023) focaram a sua pesquisa na comparação, entre algoritmos de *machine learning* tradicional e a aplicação de modelos com arquitetura *transformer*, comparando as medidas de desempenho obtidas com ambas as aplicações. Neste sentido, utilizaram o *dataset IMDb Movie Reviews*, tendo de converter os dados em vetores segundo o método *TF-IDF* para a aplicação dos modelos tradicionais. Assim, os autores concluíram que embora os modelos tradicionais sejam mais simples, a arquitetura *transformer* demonstra-se a mais adequada para alcançar a máxima precisão na tarefa de análise de sentimentos. Contudo, os autores destacaram também que entre os modelos tradicionais, o *SVM* combinado com *TF-IDF* demonstrou ser uma excelente alternativa quando não é possível dispor de poder computacional suficiente para correr o *BERT*.

Por fim, Bari, M. S. *et al.* (2025) focaram-se na comparação da avaliação do desempenho de *AI* generativa para a realização de diversas tarefas de *NLP*, recorrendo à utilização de diversos *datasets* como fonte de dados para a análise de sentimentos. Neste sentido, os autores concluíram que o *ChatGPT* demonstrou uma maior compreensão em contextos criativos e com linguísticas complexas, enquanto o *DeepSeek* foi mais eficiente em tarefas estruturadas envolvendo o raciocínio lógico. Especificamente no que toca à análise de sentimentos, o *DeepSeek* desmontrou ser uma boa alternativa e económica, enquanto o *ChatGPT* é mais aconselhado para interpretações que exijam maior sensibilidade.

1. Dados Utilizados

Como fonte de dados, recorreu-se à utilização do *dataset imdb_reviews_test.csv*, que corresponde a um conjunto de duas mil *reviews* de filmes do *IMDb*, classificadas quanto ao seu sentimento em duas categorias: positivo (*pos*) e negativo (*neg*). Cada registo contém o texto da *review*, o respetivo rótulo e o número de tokens.

Quanto à distribuição das classes esta mostrou-se equilibrada, contendo mil e vinte e duas *reviews* positivas e novecentas e setenta e oito negativas, o que é adequado para tarefas de classificação, evitando enviesamentos nos modelos. Relativamente ao tamanho das *reviews*, o número médio de tokens é de duzentos e vinte e dois, variando entre catorze e quinhentos e doze. Em termos gerais, as *reviews* apresentam cerca de cento e setenta e seis palavras e aproximadamente novecentos e setenta e um caracteres, evidenciando uma grande variabilidade no comprimento dos textos.

Com a análise dos dados foi possível verificar que as *reviews* são compostas por linguagem natural rica, com opiniões detalhadas e expressões emocionais. Após o pré-processamento (conversão para minúsculas, remoção de pontuação e *stop words*, e tratamento da negação), observou-se uma simplificação do texto, mantendo-se apenas os termos mais relevantes para a realização da análise de sentimentos.

Em suma, a *dataset* apresentou as características adequadas para o desenvolvimento de modelos de análise de sentimentos, nomeadamente equilíbrio entre classes, dimensão suficiente e conteúdo textual representativo do domínio de *reviews* de filmes.

2. Limpeza e Pré-Processamento dos Dados

Após uma primeira análise ao *Dataset*, procedeu-se a uma fase de limpeza e pré-processamento dos dados, subdividindo esta fase em três subfases. Neste sentido, fez uma limpeza inicial aos mesmos, seguida de técnicas de normalização e, por fim, aplicou-se o tratamento de negação.

Assim, para a limpeza inicial, começou por se assegurar que todo o texto fosse convertido em letras minúsculas recorrendo-se para esse efeito à biblioteca *spacy*. Desta forma, carregou-se o modelo *en_core_web_sm*, treinado na língua inglesa, capaz de distinguir substantivos, verbos ou entidades como pessoas, lugares, nomes de empresas, entre outros, com o objetivo de ao fazer a conversão para letras minúsculas, nos nomes das entidades fossem preservadas as letras maiúsculas. Assim, a função *smart_lower_spacy*, foi construída com o objetivo de processar o texto *token* por *token*, i.e., palavra a palavra, identificando a função gramatical de cada uma, para que caso fosse identificada uma entidade as letras maiúsculas fossem preservadas (*token.text_with_ws*), e caso a fosse qualquer outra palavra fosse feita a conversão para minúsculas (*token.lower_*) e adicionado o espaço após a palavra (*token.whitespace_*). Após esta transformação garantiu-se que, por exemplo, títulos com US fosse reconhecido como *United States* e não como "us" (nós).

De seguida, efetuou-se a limpeza para garantir a remoção da pontuação no texto, recorrendo-se à importação de uma *string* (*string.punctuation*), uma *string* do módulo nativo do *Python* que contém uma lista pré-

definida com todos os caracteres considerados pontuação pelo programa. Assim, os dois primeiros argumentos de *str.maketrans(", ", string.punctuation)* indicam que nenhum caracter será substituído por outro, e o último argumento indica que todos os caracteres presentes na *string* mencionada devem ser emovidos.

Quanto às *stop words*, i.e., palavras que ocorrem várias vezes num idioma, no caso do *dataset* (“the”, “is”, “at”), mas que não apresentam um significado semântico relevante para as análises, foi aplicada uma técnica para a sua remoção. Assim em *nlk.download('stopwords')*, recorreu-se à biblioteca NLTK que contém uma lista oficial de palavras irrelevantes na língua inglesa, e o objetivo da função *df_stopwords['text'].str.split()*, foi transformar cada linha em uma lista de palavras individuais, para se poder verificar elemento a elemento se determinada palavra pertencia à lista de *stop words*, e caso não pertence com o uso do *join()* ser criada uma nova frase.

Após a limpeza inicial estar completa, passou-se à aplicação da técnica de normalização lematização, uma técnica utilizada para reduzir cada palavra ao seu lema. Desta forma, começou por se descarregar três recursos essenciais da biblioteca NLTK, um dicionário semântico de forma a ser possível encontrar a raiz de cada palavra (*wordnet*), um suporte multilíngue para o dicionário (*omw-1.4*) e, um modelo capaz de identificar a classe gramatical de cada palavra (*averaged_perceptron_tagger_eng*). Assim, de forma a apoiar a função principal, construiu-se a função *get_wordnet_pos()*, que recorrendo a *nlk.pos_tag* mapeia as *tags* do NLTK de forma a que adjetivos sejam codificados com J, verbos com V, substantivos com N e, advérbios com R. O objetivo desta função auxiliar, foi garantir que no caso do exemplo da palavra “leaves”, fosse feita a classificação correta uma vez que a palavra em inglês tanto pode ser o plural de folha (*leaf*), como o verbo partir. Por fim, construiu-se a função principal *lemmatize_text()*, onde esta inicia por dividir a frase em palavras (*text.split()*), passando à identificação da função gramatical de cada palavra e aplicação da técnica de lematização (*lemmatizer.lemmatize(word, get_wordnet_pos(word))*) garantindo que “reading” passe a “read” enquanto um verbo, e por fim ser feito um *join()* agrupando as palavras lematizadas de volta numa frase. À coluna *text_with_neg_word* foi aplicado o mesmo tratamento, e incluído o tratamento da negação.

Para além dos tratamentos supramencionados, acrescentou-se também uma coluna com o tratamento das *stop words* aplicado, mas sem o tratamento da negação, uma vez que para as experiências a aplicar de seguida, em alguns dos casos é necessário que este tratamento ainda não esteja feito.

3. Metodologia de trabalho

3.1 Aplicação de Modelos existentes aos Dados de teste

Nesta etapa foram aplicados diferentes modelos de análise de sentimentos ao conjunto de dados de teste, sem qualquer treino adicional, com o objetivo de comparar abordagens baseadas em léxicos e modelos baseados em transformadores.

3.1.1 Modelos baseados em Léxicos e Regras

Desta forma, foram utilizados quatro métodos: *TextBlob*, *VADER*, *Stanza* e *SentiWordNet*, todos baseados em léxicos de polaridade e regras heurísticas para determinar o sentimento global dos textos. Quanto aos resultados obtidos, destacam-se: *TextBlob*, $F1\text{-score} = 0,765$, com elevado *recall* (0,92), *Stanza*, $F1\text{-score} = 0,757$, com elevada precisão (0,86), *VADER* $F1\text{-score} = 0,733$, *SentiWordNet*, $F1\text{-score} = 0,694$. Estes resultados são comparáveis aos reportados por Azahree & Alias (2024), que aplicaram o modelo *VADER* a críticas de filmes do *IMDb*, obtendo uma *accuracy* de aproximadamente 70% e $F1\text{-score}$ de 0,74.

3.1.2 Modelos baseados em Transformadores

Foi utilizado o modelo *DistilBERT* (distilbert-base-uncased-finetuned-sst-2-english), um modelo pré-treinado baseado em transformadores, obtendo-se os seguintes resultados: *Accuracy*: 0,7725, *Precision*: 0,8765, *Recall*: 0,6458, $F1\text{-score}$: 0,7437. Assim concluiu-se que o modelo apresentou elevada precisão, mas um *recall* inferior, indicando uma tendência mais conservadora na classificação. Os resultados obtidos são inferiores aos reportados por Ling (2024), que, após *fine-tuning* do modelo *DistilBERT* em dados do *IMDb*, obteve uma *accuracy* de 0,88 e $F1\text{-score}$ de 0,883.

3.1.3 Comparação dos Modelos

Model	Accuracy	Precision	Recall	F1-Score
TextBlob	0.7115	0.6548	0.9207	0.7654
Stanza	0.7790	0.8643	0.6732	0.7569
DistilBERT	0.7725	0.8765	0.6458	0.7437
VADER	0.6740	0.6301	0.8767	0.7332
SentiWordNet	0.6270	0.5973	0.8288	0.6943

Tabela 1 – Resultado de Modelos existentes aos Dados de teste

Efetuando-se a comparação global dos modelos conclui-se que: *TextBlob* apresentou o melhor $F1\text{-score}$ (0,7654), *Stanza* e *DistilBERT* tiveram desempenhos semelhantes, *VADER* apresentou resultados intermédios e *SentiWordNet* teve o pior desempenho. De forma geral, verificou-se que os diferentes modelos apresentam

desempenhos próximos, com ligeira vantagem para alguns métodos baseados em léxico no contexto específico do *dataset* utilizado.

3.2 Aplicação de Léxico de sentimentos

3.2.1 Pré-processamento dos léxicos

Para a aplicação de métodos com léxico de sentimentos, foi primeiro efetuado o pré-processamento do léxico *NRC-lexicon.csv* e dos dois ficheiros do *Opinion Lexicon*.

No ficheiro *NRC-lexicon.csv*, foram mantidas apenas as colunas necessárias ('English', 'Positive', 'Negative'), procedendo-se à remoção de linhas vazias (caso existissem) e à conversão do léxico para um formato de dicionário, resultando numa estrutura como ('aback', {'positive': 0, 'negative': 0}). Além disso, as chaves do dicionário (as próprias palavras) foram convertidas para letras maiúsculas. Quanto ao outro léxico selecionado, o *Opinion Lexicon* (Bing Liu Lexicon), ambos utilizam a polaridade na sua classificação e servem para estabelecer uma *baseline*, tendo sido possível realizar uma comparação do desempenho final entre os dois.

Originalmente, existiam dois ficheiros *.txt* (*negative-words.txt* e *positive-words.txt*) para o *Opinion Lexicon*, pelo que de forma a facilitar operações futuras, estes foram unificados e transformados num único ficheiro *opinion_lexicon.csv*. Este novo ficheiro passou a guardar todas as palavras positivas e negativas na coluna “English” e a respetiva classificação nas colunas ‘Positive’ e ‘Negative’. Por fim, foram efetuados pré-processamentos semelhantes aos do ficheiro NRC.

3.2.2 Criação de classificador de análise de sentimentos baseado nos dois léxicos

Para classificar os dados de teste sem tratamento da negação, foi desenvolvido um classificador sem tratamento de negação, no qual apenas seriam consideradas palavras com polaridade positiva ou negativa, sendo ignoradas todas as palavras de negação. A classificação final atribuída a cada frase foi obtida através da comparação entre o número total de palavras positivas e negativas identificadas no texto. Caso o número de palavras positivas fosse superior ao de palavras negativas, a frase seria classificada como positiva, caso contrário, seria classificada como negativa.

Este classificador foi avaliado utilizando dois léxicos de polaridade distintos: o *NRC-Lexicon* e o *Opinion Lexicon*. A classificação foi aplicada à coluna *Text* do *dataset* pré-processado, na qual foram realizadas todas as etapas de pré-processamento, incluindo normalização, remoção de pontuação, lematização/*stemming*, eliminação de *stopwords* e *negation words*. Foi utilizado o *dataset* com as *negation words* que foram removidas durante esta fase, uma vez que este classificador não considera o efeito da negação na polaridade das palavras.

Quanto às limitações do classificador sem negação, este apresentou limitações significativas ao ignorar completamente a presença de negação no texto. Expressões como “*not good*” ou “*no interesting*” tenderam a ser classificadas incorretamente como positivas, uma vez que a palavra de valor semântico positivo é considerada isoladamente. Assim, este método não foi capaz de capturar o contexto linguístico da frase, sendo particularmente inadequado para textos de opinião, onde a negação é frequente.

Para classificar os dados de teste com tratamento da negação, foi desenvolvido um classificador com tratamento de negação, recorrendo a uma lista de *negation words* baseada em Farooq (2017). Foi adotado o método tradicional de tratamento da negação, amplamente reportado na literatura, no qual, sempre que o classificador deteta-se uma palavra de negação do tipo sintática ou *diminisher*, a polaridade das duas palavras seguintes seria afetada, ocorrendo a inversão da sua polaridade original. No caso da detecção de uma negação morfológica, a palavra afetada torna-se diretamente como negativa.

Este método foi ajustado com base nos princípios descritos por Polanyi e Zaenen (s.d.), que introduzem o conceito de *valence shifters*, responsáveis por modificar o valor semântico de palavras subjetivas no seu contexto. Tal como no classificador anterior, a avaliação foi realizada utilizando os léxicos *NRC Lexicon* e *Opinion Lexicon*. Neste sentido, a classificação foi aplicada a uma nova coluna do *dataset*, criada durante a fase de pré-processamento, na qual as *negation words* foram mantidas explicitamente, permitindo a sua detecção e tratamento durante a fase de classificação.

Quanto às limitações do classificador com negação, apesar de melhorar a coerência semântica dos resultados relativamente ao classificador sem negação, esta abordagem continuou a apresentar limitações. O escopo da negação foi definido através de uma janela fixa, o que pode não ter refletido corretamente a estrutura sintática real da frase. Em construções linguísticas mais complexas, a negação pode afetar palavras fora dessa janela ou, em certos casos, não implicar inversão de polaridade. Além disso, o método não considerou relações gramaticais ou dependências sintáticas, limitando a sua capacidade de generalização para frases mais elaboradas.

Comparação de classificador à base de diferente experiência

Classificador	Accuracy	Precision	Recall	F1-Score
NRC-Lexicon (sem negação)	0.6540	0.6231	0.8170	0.7070
Opinion-Lexicon (sem negação)	0.7260	0.7347	0.7260	0.7303

NRC-Lexicon (com negação)	0.6470	0.6401	0.7065	0.6716
Opinion-Lexicon (com negação)	0.6895	0.7318	0.6194	0.6709

Tabela 2 – Resultado de classificação dos classificadores com diferentes experiências

Os resultados obtidos demonstraram que o desempenho dos classificadores varia consoante o léxico utilizado e a inclusão do tratamento de negação. Sem tratamento de negação, o classificador baseado no *Opinion Lexicon* apresentou o melhor desempenho global, registando os valores mais elevados de *accuracy* (0.726) e *F1-score* (0.730). Em contraste, o classificador baseado no *NRC-Lexicon* sem negação destacou-se pelo valor elevado de *recall* (0.817), indicando uma maior capacidade de identificação de instâncias positivas, embora com menor *precision*.

Com a introdução do tratamento de negação, observou-se uma diminuição do desempenho global em ambos os léxicos. No *NRC-Lexicon*, o *F1-score* reduz-se de 0.707 para 0.672, enquanto no *Opinion Lexicon* diminui de 0.730 para 0.671. Estes resultados indicam que o impacto do tratamento de negação não é uniforme e depende do léxico utilizado.

3.3 Treino de modelos de aprendizagem automática

Nesta etapa, pretendeu-se treinar modelos de classificação automática com o objetivo de melhorar os resultados obtidos nas secções anteriores. Para tal, foram exploradas duas abordagens distintas: modelos clássicos de aprendizagem automática com representação *TF-IDF*, e o *fine-tuning* de um modelo pré-treinado baseado em transformadores.

Antes de se proceder ao treino dos modelos clássicos, foi necessário converter os textos das *reviews* numa representação numérica que pudesse ser utilizada como entrada para os algoritmos de classificação. Para esse efeito, optou-se pela utilização do método *TF-IDF*, implementado através da classe *TfidfVectorizer* da biblioteca *scikit-learn*. Esta técnica atribui a cada palavra um peso proporcional à sua frequência no documento, penalizado pela sua frequência no conjunto total de documentos, permitindo assim destacar termos mais discriminativos.

A configuração utilizada foi a seguinte: *max_features* = 10000, limitando o vocabulário às 10000 *features* mais relevantes; *ngram_range* = (1,2), permitindo capturar não apenas palavras individuais (unigramas), mas também pares de palavras consecutivas (bigramas), o que se revela particularmente útil para expressões compostas frequentes em *reviews* de filmes, como “*very good*” ou “*not bad*”; e *sublinear_tf* = True, que aplica

uma transformação logarítmica à frequência dos termos, atenuando o impacto de palavras que ocorrem com frequência excessiva num único documento.

A representação *TF-IDF* foi ajustada sobre o *dataset* de treino (*imdb_reviews_train.csv*), composto por 41750 *reviews*, e posteriormente aplicada ao *dataset* de teste, resultando numa matriz de dimensões 41750×10000 para o treino e 2000×10000 para o teste.

3.3.1 Métodos de classificação automática

Foram selecionados quatro métodos de classificação da biblioteca *scikit-learn*, de forma a cobrir diferentes famílias de algoritmos: Regressão Logística - modelo linear que estima a probabilidade de pertença a cada classe, configurado com *max_iter* = 1000 e *C* = 1.0.; *Naive Bayes* - classificador probabilístico baseado no teorema de *Bayes*, particularmente adequado para dados de contagem de texto, configurado com *alpha* = 1.0; Máquinas de Vetores de Suporte (LinearSVC) - modelo que procura encontrar o hiperplano que maximiza a margem de separação entre as classes, configurado com *max_iter* = 2000 e *C* = 1.0; *Random Forest* (*RandomForestClassifier*) - método de *ensemble* baseado em múltiplas árvores de decisão, configurado com *n_estimators* = 100, *n_jobs* = -1 e *random_state* = 42.

Cada modelo foi treinado com o *dataset* de treino completo e avaliado sobre o *dataset* de teste. Os resultados obtidos foram os seguintes:

Modelo	Accuracy	Precision	Recall	F1-Score
Regressão Logística	0.8925	0.8968	0.8924	0.8946
SVM (LinearSVC)	0.8900	0.8893	0.8963	0.8928
Naive Bayes	0.8685	0.8769	0.8640	0.8704
Random Forest	0.8505	0.8723	0.8288	0.8500

Tabela 3. Comparação entre os modelos

A Regressão Logística obteve o melhor desempenho global, com um F1-score de 0,8946, seguida de perto pelo *SVM* com um *F1-score* de 0,8928. Ambos os modelos superaram significativamente todos os modelos baseados em léxicos apresentados nas secções anteriores, com uma diferença de aproximadamente 13 pontos percentuais em *F1-score*. Este resultado é consistente com os obtidos por Rathore et al. (2023), que no seu estudo também demonstraram que o *SVM* combinado com *TF-IDF* constitui uma excelente alternativa quando não se dispõe de poder computacional suficiente para a aplicação de modelos baseados em transformadores.

O *Naive Bayes* apresentou resultados sólidos ($F1\text{-score} = 0,8704$), sendo computacionalmente muito eficiente, o que o torna adequado para cenários onde o tempo de processamento é uma restrição relevante. O *Random Forest*, embora ligeiramente abaixo dos restantes modelos, manteve ainda assim um desempenho superior ao de qualquer modelo baseado em léxico, evidenciando que a abordagem supervisionada com representação *TF-IDF* é claramente mais eficaz para esta tarefa.

3.3.2 Fine-tuning de modelo pré-treinado baseado em transformadores (DistilBERT)

Para além dos modelos clássicos, procedeu-se ao *fine-tuning* do modelo *distilbert-base-uncased*, um modelo pré-treinado baseado na arquitetura *transformer*. Conforme referido por Ling (2024), o *DistilBERT* é uma versão mais leve do *BERT* que reduz em 40% o número de parâmetros, mantendo praticamente a totalidade do desempenho do modelo original, o que o torna mais adequado para execução em ambientes com recursos computacionais limitados.

Ao contrário dos modelos clássicos, que requerem uma conversão explícita do texto para uma representação numérica (como o *TF-IDF*), o *DistilBERT* efetua automaticamente a tokenização do texto através do seu *tokenizador* integrado (*DistilBertTokenizerFast*). Este *tokenizador* transforma cada palavra em identificadores numéricos (*input_ids*) que alimentam diretamente a rede neuronal, dispensando a necessidade de aplicar técnicas de vetorização externas. Assim, o modelo recebe o texto quase em bruto e aprende representações contextuais durante o processo de treino.

A evolução do treino ao longo das épocas foi a seguinte: Amostra de treino: 2 000 *reviews* estratificadas (1000 positivas + 1000 negativas), devido a limitações computacionais (CPU); Épocas: 2; *Learning rate*: $2e-5$; Comprimento máximo de sequência: 128 *tokens*; *Batch size*: 32 (treino) / 64 (avaliação); *Warmup ratio*: 0,1 | *Weight decay*: 0,01

Época	Training Loss	Validation Loss	Accuracy	F1
1	0.6280	0.4145	0.8295	0.8250
2	0.3756	0.3749	0.8485	0.8511

Tabela 4. Evolução do treino

Modelo	Accuracy	Precision	Recall	F1-Score
DistilBERT Fine-tuned	0.8485	0.8549	0.8474	0.8511

Tabela 5. Resultado final no dataset de teste

Com o *fine-tuning*, o *DistilBERT* melhorou significativamente o seu desempenho face à versão pré-treinada sem ajuste, apresentada na secção 3.1.2, passando de um *F1-score* de 0,7437 para 0,8511, o que corresponde a um aumento de 14,4 pontos percentuais. Este resultado confirma a importância da adaptação do modelo ao domínio específico dos dados, tal como demonstrado por Ling (2024), que reportou um *F1-score* de 0,883 após o *fine-tuning* completo do *DistilBERT* com o *dataset* *IMDb*.

3.3.3 Comparação e síntese dos resultados:

A comparação entre os modelos clássicos e o modelo baseado em transformadores é apresentada na tabela seguinte, ordenada por *F1-score*:

Modelo	F1-Score
Regressão Logística (TF-IDF)	0.8946
SVM (TF-IDF)	0.8928
Naive Bayes (TF-IDF)	0.8704
DistilBERT Fine-tuned	0.8511
Random Forest (TF-IDF)	0.8500

Tabela 6. Comparação do desempenho ordenado pelo *F1-score*

A melhoria observada da época 1 para a época 2 ($F1: 0,825 \rightarrow 0,851$) sugere que a utilização do dataset completo de treino e de um maior número de épocas permitiria alcançar resultados superiores. Ling (2024) obteve um *F1-score* de 0,883 com o *fine-tuning* completo, o que reforça esta hipótese.

Em suma, os resultados obtidos confirmam que, para tarefas de classificação de sentimentos em reviews de filmes, tanto os modelos clássicos com *TF-IDF* como os baseados em transformadores constituem abordagens eficazes, sendo a escolha entre ambos condicionada fundamentalmente pelos recursos computacionais disponíveis e pelo volume de dados de treino. A Regressão Logística com *TF-IDF* revelou-se a melhor abordagem neste estudo, com um *F1-score* de 0,8946, oferecendo simultaneamente rapidez de treino, interpretabilidade do modelo e elevada eficácia na classificação.

3.4 Análise de sentimentos do texto com AI

Para efetuar a análise de sentimentos recorrendo a IA, foi utilizado o agente Gemini, pois com base na revisão da literatura, apenas foi explorado o tema com recurso aos agentes ChatGPT e DeepSeek, tendo-se concluindo que ambos são boas opções para efetuar a análise. Neste sentido, de forma a gerar novo conhecimento optou-se por um agente de IA diferente dos utilizados.

Assim, para efetuar o teste, recorreu-se à utilização de duas *reviews* previamente classificadas no *dataset*, conforme Anexo 1, sendo que a primeira *review* foi classificada como negativa, e a segunda *review* foi classificada como positiva. Desta forma, começou por se testar a capacidade de análise de sentimentos do Gemini, com uma *prompt* simples, sem qualquer contexto, conforme Anexo 2, tendo o mesmo sido capaz de identificar corretamente o sentimento presente em cada *review* e, inclusive, feito uma análise acerca dos pontos positivos e críticos de cada *review*.

De seguida, aplicou-se uma *prompt* onde foi dado algum contexto ao agente, conforme Anexo 3, sendo que nessa vez, a resposta gerada manteve-se consistente com os resultados reais e, tendo o agente feito uma maior caracterização de cada *review* justificando a sua escolha. Por fim, com a *prompt* final, com contexto e com um exemplo de como deveria classificar cada *review*, o agente foi capaz de uma vez mais fazer a classificação correta, e desta vez apresentou a sua justificação com base em palavras identificadas em cada *review*.

Desta forma, foi possível concluir que o agente Gemini, apresenta uma excelente sensibilidade para a tarefa de análise de sentimentos. Ainda que não lhe seja dado muito contexto numa primeira instância, o mesmo é capaz de fazer uma boa classificação do sentimento presente em cada texto, sendo que à medida que se vai aumentado a especificação da *prompt*, aumenta também a precisão da justificação sugerida.

4. Discussão dos Resultados

4.1 Comparação entre modelos baseados em léxico e transformadores

Os resultados obtidos evidenciam diferenças claras entre os modelos baseados em léxico e o modelo baseado em transformadores. Apesar de o *DistilBERT* representar uma abordagem mais avançada, o seu desempenho não superou de forma significativa os melhores modelos baseados em léxico, como o *TextBlob* e o *Stanza*.

Este comportamento pode ser explicado pelo facto de o modelo *DistilBERT* ter sido utilizado sem *fine-tuning* específico sobre a *dataset* em estudo. Tal como demonstrado por Ling (2024), o desempenho deste tipo de modelos melhora significativamente quando ajustados a dados do domínio, podendo atingir valores de *F1-score* superiores a 0,88. Assim, a ausência de adaptação ao domínio *IMDb* constitui uma limitação relevante neste trabalho. Por outro lado, os modelos baseados em léxico apresentaram resultados competitivos, especialmente o *TextBlob*, que alcançou o melhor *F1-score*. Este resultado pode dever-se ao equilíbrio entre precisão e *recall*, bem como à simplicidade do método. No entanto, estes modelos apresentam limitações conhecidas, nomeadamente a

incapacidade de capturar contexto, ironia e dependências semânticas complexas, como referido por Azahree & Alias (2024).

4.2 Comparação de resultados entre o classificador com tratamento e sem tratamento

A introdução do tratamento de negação teve como objetivo melhorar a coerência linguística da classificação, nomeadamente em frases que contêm construções negativas. Contudo, os resultados obtidos mostram que esta melhoria conceptual não se refletiu numa melhoria consistente das métricas quantitativas, como *accuracy* ou *F1-score*. Em ambos os léxicos analisados, verificou-se uma diminuição do desempenho global após a inclusão do tratamento de negação.

Este comportamento está de acordo com a literatura, que refere que a adição do tratamento de negação pode melhorar a interpretação semântica das frases, mas não garante ganhos nas métricas de avaliação clássicas, especialmente quando são utilizados métodos tradicionais baseados em janelas fixas (Bing Liu, 2012; Farooq et al., 2016). A descida mais acentuada do *recall* no Opinion Lexicon sugere que a inversão de polaridade pode ter sido aplicada a palavras que não eram semanticamente afetadas pela negação.

No caso do NRC-Lexicon, a maior cobertura lexical torna o classificador mais sensível a erros na determinação do escopo da negação, o que explica a redução simultânea do *recall* e do *F1-score*. Assim, os resultados confirmam que classificadores baseados em léxico, mesmo com tratamento de negação, apresentam limitações na modelação do contexto linguístico, devendo ser encarados como abordagens de *baseline* em tarefas de análise de sentimentos.

4.3 Comparação de modelos de aprendizagem automática

Os resultados obtidos com os modelos de aprendizagem automática evidenciam uma clara superioridade das abordagens supervisionadas face aos modelos baseados em léxicos e regras apresentados nas secções anteriores. A Regressão Logística obteve o melhor *F1-score* global (0,8946), seguida de perto pelo *SVM* (0,8928), representando uma melhoria de aproximadamente 13 pontos percentuais face ao melhor modelo baseado em léxico (*TextBlob*, *F1-score* = 0,7654).

Entre os modelos clássicos, a Regressão Logística e o *SVM* apresentaram desempenhos muito semelhantes, com diferenças inferiores a 0,2 pontos percentuais. Ambos beneficiam da representação *TF-IDF* com bigramas, que captura eficazmente padrões discriminativos no texto, e da sua natureza linear, que se adequa particularmente bem a espaços de alta dimensionalidade como os gerados pelo *TF-IDF*. O *Naive Bayes*, apesar de apresentar um

F1-score ligeiramente inferior (0,8704), constitui uma alternativa computacionalmente muito eficiente, podendo ser relevante em cenários com grandes volumes de dados e restrições temporais. O *Random Forest*, enquanto método de ensemble não linear, obteve o pior desempenho entre os modelos clássicos (*F1-score* = 0,8500), sugerindo que a não linearidade não acrescenta valor significativo para esta tarefa com a representação utilizada.

No que diz respeito ao *DistilBERT fine-tuned*, o seu *F1-score* de 0,8511 ficou abaixo dos melhores modelos clássicos, mas representa uma melhoria substancial face à versão pré-treinada (*F1* = 0,7437). Esta diferença de desempenho em relação aos modelos clássicos pode ser atribuída à utilização de uma amostra reduzida de treino (2000 *reviews* versus 41750), imposta pelas limitações computacionais do ambiente de execução (CPU). Conforme demonstrado por Ling (2024), com o *dataset* completo e recursos computacionais adequados (GPU), o *DistilBERT fine-tuned* pode alcançar um *F1-score* de 0,883, superando os modelos clássicos.

Em termos de *trade-off* entre desempenho e custo computacional, os modelos clássicos com *TF-IDF* apresentam uma relação claramente mais favorável neste contexto. O treino da Regressão Logística é efetuado em poucos segundos, enquanto o *fine-tuning* do *DistilBERT* na mesma máquina requereu cerca de 20 minutos com apenas 2000 exemplos de treino.

Conclusão

O presente trabalho teve como objetivo comparar diferentes abordagens para a classificação de sentimentos em dados textuais, utilizando um dataset de reviews do IMDb, incluindo métodos baseados em léxicos, modelos de transformadores e técnicas de aprendizagem automática.

Os resultados evidenciam diferenças claras entre as abordagens. Os modelos baseados em léxicos, embora simples e eficientes, apresentam limitações na captura de contexto linguístico, sendo mais adequados como baseline. Já os modelos baseados em transformadores demonstraram maior capacidade de modelação contextual, sobretudo após *fine-tuning*, ainda que o seu desempenho tenha sido condicionado por limitações computacionais.

Os modelos clássicos de aprendizagem automática, nomeadamente Regressão Logística e SVM com *TF-IDF*, apresentaram o melhor desempenho global, destacando-se pelo equilíbrio entre eficácia e custo computacional. Por outro lado, os modelos baseados em instruções, como o Gemini, revelaram forte capacidade interpretativa, embora sem avaliação quantitativa rigorosa neste estudo.

Como principais limitações destacam-se as restrições computacionais e a avaliação limitada dos modelos baseados em instruções. Como trabalho futuro, propõe-se a exploração de modelos transformer com mais dados,

arquiteturas mais avançadas e abordagens híbridas, bem como uma avaliação quantitativa mais abrangente dos modelos baseados em instruções.

Em síntese, a escolha da melhor abordagem depende do contexto, dos recursos disponíveis e da complexidade dos dados, não existindo uma solução universalmente superior.

Bibliografia

Azahree, A., & Alias, R. (2024). Understanding viewer opinions: Sentiment analysis on movie review using VADER and LSTM model. *Proceedings of Sci. Math.*, 24.

Comparative evaluation of ChatGPT and DeepSeek across key NLP tasks: Strengths, weaknesses, and domain-specific performance. (2025). *arXiv*. <https://doi.org/10.48550/arXiv.2501.13310>

Data, N. (2017). *Opinion lexicon*. Kaggle. <https://www.kaggle.com/datasets/nltkdata/opinion-lexicon>

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *arXiv*. <https://arxiv.org/abs/1810.04805>

Farooq, U. (2017). Negation Handling in Sentiment Analysis at Sentence Level. *Journal of Computers*, 470–478. <https://doi.org/10.17706/jcp.12.5.470-478>

GeeksforGeeks. (2017, 22 de maio). *Removing stop words with NLTK in Python*. <https://www.geeksforgeeks.org/removing-stop-words-nltk-python/>

González-Carvajal, S., & Garrido-Merchán, E. C. (2020). Comparing BERT against traditional machine learning text classification. *arXiv*. <https://arxiv.org/abs/2005.13010>

Khoo, C. S. G., & Johnkhan, S. B. (2016). Lexicon-based sentiment analysis: Comparative evaluation of six sentiment lexicons. *Journal of Information Science*, 42(2), 173–190. <https://doi.org/10.1177/0165551517703514>

Ling, X. (2024). Fine-tuning DistilBERT for enhanced sentiment classification. *Journal of Big Data and Computing*, 2.

Liu, B. (2015). *Opinion mining, sentiment analysis, opinion extraction*. University of Illinois Chicago. <https://www.cs.uic.edu/~liub/FBS/sentiment-analysis.html>

Polanyi, L., & Zaenen, A. (n.d.). Contextual Valence Shifters. The Information Retrieval Series, 1–10. https://doi.org/10.1007/1-4020-4102-0_1

Saldaña, Z. W. (2018, 15 de janeiro). Análise de sentimento para exploração de dados. *Programming Historian*. <https://programminghistorian.org/pt/licoes/analise-sentimento-exploracao-dados>

Sentiment analysis of IMDb movie reviews using traditional machine learning techniques and transformers. (2023). [Inserir nome da fonte/revista].

Vanitha, B., & Vanathi, A. (2024). Advanced political threat forecasting using hybrid lexicon and ML techniques. *TELKOMNIKA (Telecommunication, Computing, Electronics and Control)*.

Anexos

Anexo 1 – Reviews Escolhidas para testes

1 Review - Negativa

If it wasn't for the bad dialogues and script. I mean, the direction was really in touch with it's subject. The actors were doing good at bringing their characters to life. But in the end, the thing that was really missing was a solid script to hold all the pieces together. I would highly suggest not to watch this. Unless you're a Al Pacino enthusiast like I am and will watch everything he is playing in. Even if the result lately are rather poor. This is, after S1m0ne, a second very bad movie for this actor that once knew how to choose roles.

2 Review - Positiva

I really liked this movie. If other people want to give it an average around 5.0 10 that's their choice. I would give it 10 10. Sutherland's performance as a private eye is totally awesome. The story is amazing, human, exciting, intelligent. The dialogue is good. The story might not be perfect but anyway the mood of the movie is good enough to compensate for that. Moreover, the ending is incredibly cool and their the jig saw puzzle really comes back to together. So anyway I liked it. I also thought the female lead actress performed very well. I'm not a big fan of detective movies but this one was really good, also because it doesn't give a damn about conventions of the supernatural.

Anexo 2 – Prompt com instrução genérica

Prompt:

Analisa o sentimento presente em cada uma destas reviews:

1. If it wasn't for the bad dialogues and script. I mean, the direction was really in touch with it's subject. The actors were doing good at bringing their characters to life. But in the end, the thing that was really missing was a solid script to hold all the pieces together. I would highly suggest not to watch this. Unless you're a Al Pacino enthusiast like I am and will watch everything he is playing in. Even if the result lately are rather poor. This is, after S1m0ne, a second very bad movie for this actor that once knew how to choose roles.

2. I really liked this movie. If other people want to give it an average around 5.0 10 that's their choice. I would give it 10 10. Sutherland's performance as a private eye is totally awesome. The story is amazing, human, exciting, intelligent. The dialogue is good. The story might not be perfect but anyway the mood of the movie is good enough to compensate for that. Moreover, the ending is incredibly cool and their the jig saw puzzle really comes back to together. So anyway I liked it. I also thought the female lead actress performed very well. I'm not a big fan of detective movies but this one was really good, also because it doesn't give a damn about conventions of the supernatural.

Resposta:

Aqui está uma análise detalhada do sentimento de cada review, destacando os pontos que sustentam essas conclusões:

Review 1: Sentimento Negativo / Decepcionado

Embora o autor reconheça aspectos técnicos positivos, a conclusão final é de forte desaprovação. O sentimento é de frustração, especialmente por vir de um fã do ator principal.

- Pontos Positivos: Elogia a direção ("in touch with its subject") e a atuação ("doing good at bringing their characters to life").
- Pontos Críticos: O roteiro e os diálogos são descritos como ruins. O autor utiliza expressões fortes como "really missing", "rather poor" e "very bad movie".
- Veredito do Autor: Uma recomendação direta para não assistir ("I would highly suggest not to watch this"), a menos que você seja um fã ávido de Al Pacino.

Review 2: Sentimento Positivo / Entusiasta

Esta review apresenta um sentimento de satisfação e empolgação. O autor discorda da média baixa da crítica e foca na experiência emocional e no entretenimento proporcionado.

- Pontos Positivos: O autor usa superlativos e adjetivos de alta intensidade: "totally awesome", "amazing", "exciting", "intelligent" e "incredibly cool". A atuação de Sutherland e da protagonista feminina é muito elogiada.

- Pontos Críticos: Admite que a história pode não ser perfeita, mas minimiza isso afirmando que a "vibe" do filme compensa qualquer falha.
- Veredito do Autor: Uma nota máxima simbólica (10/10) e uma afirmação clara de que, mesmo não sendo fã do gênero, o filme o conquistou.

Anexo 3 – Prompt com descrição do domínio de aplicação

Prompt:

Atua como um especialista em cinematografia, e analise o sentimento demonstrado por cada uma destas reviews:

1. If it wasn't for the bad dialogues and script. I mean, the direction was really in touch with it's subject. The actors were doing good at bringing their characters to life. But in the end, the thing that was really missing was a solid script to hold all the pieces together. I would highly suggest not to watch this. Unless you're a Al Pacino enthusiast like I am and will watch everything he is playing in. Even if the result lately are rather poor. This is, after S1m0ne, a second very bad movie for this actor that once knew how to choose roles.

2. I really liked this movie. If other people want to give it an average around 5.0 10 that's their choice. I would give it 10 10. Sutherland's performance as a private eye is totally awesome. The story is amazing, human, exciting, intelligent. The dialogue is good. The story might not be perfect but anyway the mood of the movie is good enough to compensate for that. Moreover, the ending is incredibly cool and their the jig saw puzzle really comes back to together. So anyway I liked it. I also thought the female lead actress performed very well. I'm not a big fan of detective movies but this one was really good, also because it doesn't give a damn about conventions of the supernatural.

Resposta:

Como especialista em cinematografia, analiso essas duas críticas sob a ótica da estrutura narrativa e do desempenho técnico. É fascinante observar como a percepção da "colagem" de elementos fílmicos dita o veredito final de cada espectador.

Aqui está a análise técnica de sentimento para cada uma:

1. Review 1: Sentimento Negativo (Decepção Técnica)

O autor demonstra um sentimento de frustração técnica, focando na desarticulação entre a forma e o conteúdo. Apesar de reconhecer méritos individuais, o veredito é de rejeição.

Ponto de Ruptura: O roteiro (script). Na cinematografia, se a "espinha dorsal" (texto) falha, a direção e a atuação tornam-se esforços isolados que não sustentam a obra.

Conflito Interno: Existe um forte viés de lealdade ao ator (Al Pacino), mas nem o fanatismo é suficiente para superar a percepção de má qualidade.

Tom: Analítico e melancólico. O autor lamenta o declínio na curadoria de papéis do ator, classificando o filme como um erro de carreira.

Palavras-Chave de Sentimento: Bad dialogues, rather poor, very bad, missing.

2. Review 2: Sentimento Positivo (Entusiasmo Imersivo)

Aqui temos um sentimento de satisfação subjetiva, onde a "atmosfera" (mood) e o carisma dos protagonistas sobrepõem-se a eventuais falhas estruturais.

Ponto de Conexão: A performance e a resolução narrativa. O espectador valoriza o "ritmo" e a conclusão (jig saw puzzle), sentindo que a experiência emocional compensa imperfeições no roteiro.

Desafio às Convenções: O autor demonstra prazer na subversão de gênero (o filme ignora convenções do sobrenatural), o que gera uma resposta positiva pela originalidade.

Tom: Defensivo e entusiasta. Ele reconhece a baixa média da crítica (5.0/10), mas reafirma sua conexão pessoal com a obra (10/10).

Palavras-Chave de Sentimento: Totally awesome, amazing, incredibly cool, really good.

Anexo 4 – Prompt refinada

Prompt:

Classifica os sentimentos presentes nas reviews abaixo, como Positivo, Negativo ou Neutro, tendo em conta que:

"bad" -> Negativo

"I like" -> Positivo

1. If it wasn't for the bad dialogues and script. I mean, the direction was really in touch with it's subject. The actors were doing good at bringing their characters to life. But in the end, the thing that was really missing was a solid script to hold all the pieces together. I would highly suggest not to watch this. Unless you're a Al Pacino enthusiast like I am and will watch everything he is playing in. Even if the result lately are rather poor. This is, after S1m0ne, a second very bad movie for this actor that once knew how to choose roles.

2. I really liked this movie. If other people want to give it an average around 5.0 10 that's their choice. I would give it 10 10. Sutherland's performance as a private eye is totally awesome. The story is amazing, human, exciting, intelligent. The dialogue is good. The story might not be perfect but anyway the mood of the movie is good enough to compensate for that. Moreover, the ending is incredibly cool and their the jig saw puzzle really comes back to together. So anyway I liked it. I also thought the female lead actress performed very well. I'm not a big fan of detective movies but this one was really good, also because it doesn't give a damn about conventions of the supernatural.

Resposta:

Com base nas instruções fornecidas e na análise do conteúdo das reviews, aqui está a classificação dos sentimentos:

Item	Review	Sentimento
1	"If it wasn't for the bad dialogues and script... This is, after S1m0ne, a second very bad movie for this actor..."	Negativo
2	"I really liked this movie... Sutherland's performance as a private eye is totally awesome... So anyway I liked it."	Positivo

Resumo da Análise:

Review 1: Apesar de elogiar a direção e os atores, o autor utiliza explicitamente o termo "bad" para descrever o roteiro e o filme, concluindo com uma recomendação para não assistir.

Review 2: O autor utiliza expressões equivalentes a "I like" (como "I really liked" e "I liked it"), além de atribuir uma nota máxima e elogiar diversos aspectos da produção.